课程大作业 SATR-SSM骨干的跨检测器迁移验证

学号 20242054 姓名 黄刘昱泽 单人组队，工作占比100%

1 实验目的与任务介绍

本项目检验SATR-SSM骨干在RF-DETR-Nano中的迁移能力。原始完整SATR-SSM检测器使用PAN-FPN与原检测头；迁移模型使用SATR-SSM骨干、新适配层及RF-DETR-Nano解码器/检测头。首先固定RF-DETR 1.3.0，在COCO2017全量80类上完成20轮预训练微调复现；日志训练耗时约48.00小时。随后建立同源5000张配对子集，在80类与VOC对应20类的共同标签空间核对基线，再分别在COCO20与M3FD可见光任务中接入SATR。

COCO20上，DINOv2-S基线与SATR骨干迁移模型的mAP50:95分别为0.544和0.006；M3FD上为0.493和0.315。两组接入的参数量分别由30.22M降至9.58M、由30.47M降至9.83M。学习率、权重更新和结构核对显示，新适配层参与了训练，迁移接口同时改变了预训练投影器、归一化方式与多尺度组合。本报告保留完整数值，并围绕接口适配与优化策略组织问题分析。

1.1 研究问题与应用背景

目标检测需要从单幅图像中给出类别、位置与置信度，在道路监测、车辆行人识别、夜间安防等场景中具有直接应用。SATR-SSM是大创成果，其原体系展示了夜间和密集目标场景的检测结果；本项目选择ICLR 2026论文RF-DETR作为接入框架，研究这类特征能否在Transformer检测器中继续发挥作用。

表1 研究步骤与已完成任务

研究阶段	对应工作
建立参照	RF-DETR-Nano全量COCO微调复现与最终权重重载验证
缩短对照周期	构造同图像5k子集，分别控制图像规模和标签空间
两次迁移	COCO20与M3FD中接入SATR，检查精度、参数量与接口
证据归档	日志、样例预测与RF-DETR基线源码随包；模型及完整预测在线下载

报告结构：方法与系统 → 数据与协议 → 参数与结果 → 失败案例与分析 → 复现与总结。

2 方法基础与系统总体设计

2.1 RF-DETR-Nano

RF-DETR发表于ICLR 2026，以DINOv2编码器、特征投影器和Transformer解码器完成集合预测，通过匹配查询与目标，联合优化分类、框回归与GIoU损失。本次固定其1.3.0代码；Nano配置为384输入、patch16、2个窗口、2层解码器和300个评估查询，训练使用13组查询。

2.2 SATR-SSM原体系

原始完整SATR-SSM检测器由SATR-SSM骨干、PAN-FPN和原检测头组成。骨干包含MGAM显著增强、MTRP路由状态传播和MTCP结构校准。本次迁移模型提取其P3/P4/P5输出，通过新适配层接入RF-DETR-Nano解码器与检测头；两者是不同的完整检测模型。

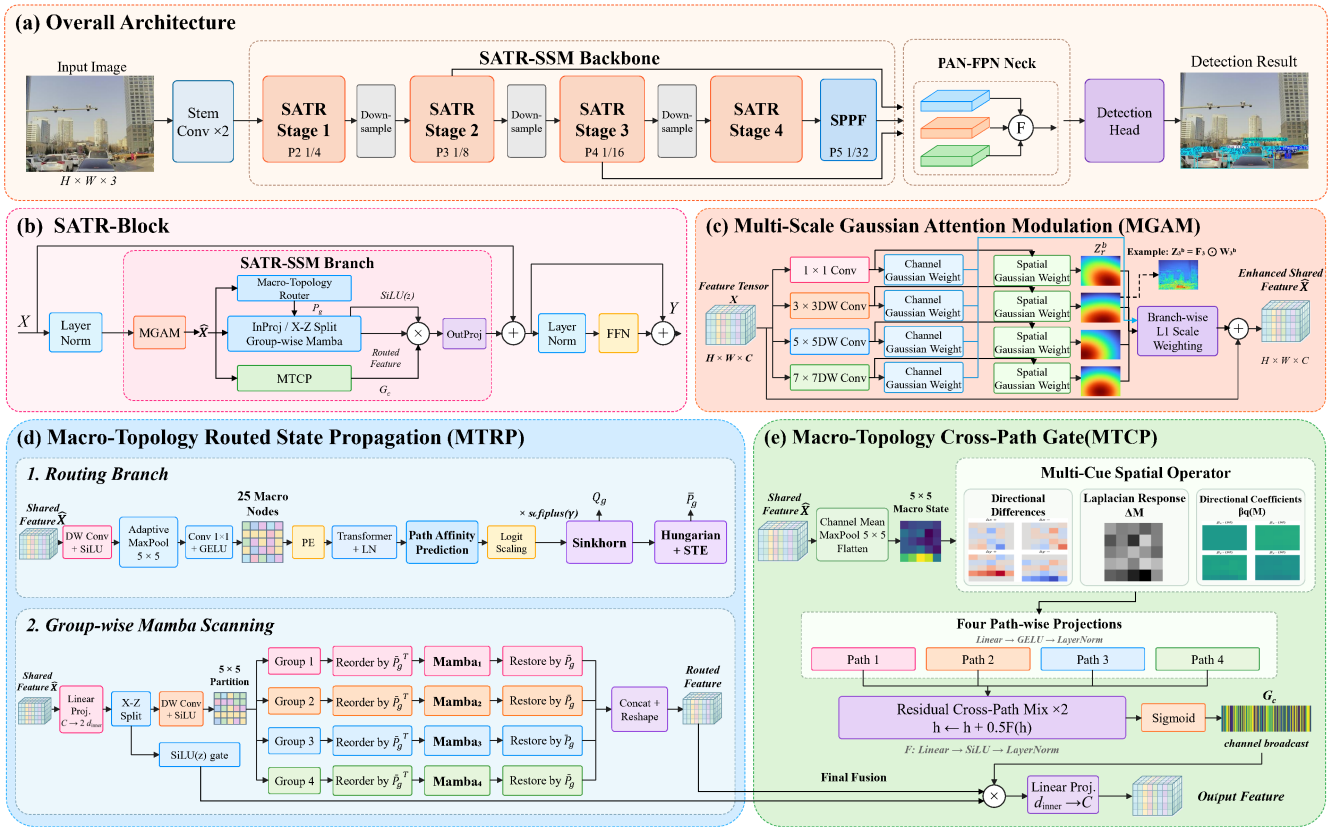


图1 原始完整SATR-SSM检测器的总体结构与核心模块。

2.3 跨检测器接口

原RF-DETR

DINOv2-S	四层特征拼接	预训练投影器	位置编码/解码器

SATR骨干迁移

SATR P3/P4/P5	1×1 Conv + GN	插值/加权融合	位置编码/解码器

统一输出 [B, 256, 24, 24]；保留 RF-DETR 位置编码、解码器与检测头。

输入先逆ImageNet归一化回[0, 1]。三路特征分别经1×1卷积及32组GroupNorm，双线性插值到P4大小；softmax归一化的全局尺度权重将其求和。padding mask同步缩放，原位置编码路径继续使用。接入包含编码器和投影模块的共同变化。

3 数据集、划分与对照设计

表2 数据集与固定划分

任务	训练/验证图像	标签与评估
COCO2017全量	118287 / 5000	80个实际类别，使用原始稀疏类别ID
COCO80-5k	5000 / 5000	固定训练子集，保留80类
COCO20-5k	同一5000 / 5000	保留与Pascal VOC对应的20类
M3FD可见光	2100 / 2100	People/Car/Bus/Motorcycle/Lamp/Truck

M3FD来源：Liu等在CVPR 2022的TarDAL论文中提出该多场景、多模态检测基准，包含红外/可见光配对图像。本项目只使用可见光分支的固定划分；它也是已有SATR权重对应的任务域。原论文和数据入口见参考文献[7]。

3.1 配对子集

seed=0，按SHA256(seed:image_id)固定选取5000张训练图。B与C/D使用同一批图像，验证集沿用全部val2017。COCO20的20个原COCO类别ID为1、2、3、4、5、6、7、9、16、17、18、19、20、21、44、62、63、64、67、72，并映射为稠密类别。其余60类目标在该任务中作为背景。分类头按原类别语义抽取初始化行。

3.2 比较口径

表3 对照问题与比较口径

问题	比较	控制与读取方式
图像规模	A / B	共同80类，保持官方初始化和课程微调设置
标签收缩	B / C	使用共同VOC20类别AP；各自总体AP分列
COCO20迁移	C / D	相同图像、类别、有效batch、学习率字段和轮数
M3FD迁移	E / F	相同可见光划分、6类任务和100轮预算

3.3 验证集与预训练来源

分类头实现：原COCO采用含稀疏ID空位的91行布局；C/D语义映射为21行。E/F沿用既有91行分类张量布局，数据本身仍为6类。该布局在模型核对记录中保留。

全部本次数值来自valid。COCO20和M3FD的test目录为valid别名，模型选择与最终汇总均记录为验证结果。RF-DETR从官方COCO权重继续训练；SATR编码器来自已有M3FD任务权重，使用satr_export_v2中audited-semantic-v2路由兼容实现。该实现通过当前运行时的严格权重加载与双CUDA探针核对；历史训练时的前向实现对应关系仍待补齐。M3FD在本项目中是已有优势域上的第二次接入检验。原始完整SATR-SSM的已有结果按既有协议单列；本次C/D、E/F分别比较相同任务中的两种RF-DETR-Nano骨干配置。

数据下载、原标注哈希、固定图像ID、类别映射及60张样例见data/。

4 实验环境、训练参数与选择依据

表4 实际训练环境与参数

设置	COCO A－D	M3FD E/F
GPU /精度	RTX2080Ti约11GB / FP32	同左
输入	384×384，固定尺度	384×384，固定尺度
单步batch /梯度累积	2 / 8，有效batch=16	相同
主学习率 /编码器字段	1e-5 / 1.5e-5	1e-4 / 1.5e-4
epochs / lr_drop	20 / 20	100 / 80
优化器 /weight decay	AdamW / 1e-4	相同
梯度裁剪 /seed	0.1 / 0	相同
控制设置	EMA、梯度检查点；无多尺度	相同
训练Python	A/B/C:3.11.17；D:3.12.3	E:3.11.17；F:3.12.3

核心依赖：PyTorch2.4.1+cu121、torchvision0.19.1+cu121、transformers4.51.3、timm1.0.15、peft0.15.2。D/F使用Mamba2.2.2和causal-conv1d1.4.0的Python3.12原生扩展。Turing显卡无原生BF16执行能力，本次关闭该AMP路径。

4.1 为什么选择这些参数

batch2配合8步累积与梯度检查点适配11GB显存。384沿用Nano结构，所有成对实验保持输入相同。COCO用1e-5继续微调官方权重，将完整与子集对照固定为20轮；M3FD用1e-4和100轮适配目标域。两类任务的参数在其内部成对固定。

4.2 原论文对照

Model Size	Resolution	Patch Size	Windows	Decoder Layers	Queries	Backbone
N	384	16	2	2	300	DINOv2-S

图2 RF-DETR论文Table7的Nano行。结构参数沿用；原文batch128与LR1e-4，本次有效batch16，COCO主LR1e-5。原始SATR检测器输入640，本次接口统一384；课程实验采用2080Ti与PyTorch2.4.1。

本次复现的完整链路为既有预训练权重、课程微调、最佳checkpoint重载和COCO评估；各项原参数和环境记录均随包保留。

5 实验结果总表

mAP取值范围为0至1，统一保留三位小数。A－F为本次RF-DETR-Nano最佳权重重载验证，末行为原始完整SATR-SSM检测器的已有结果。参数量为整个检测模型，M表示百万参数。

表5 六组正式结果与原论文参考

模型 + Backbone	数据集	参数M	mAP50:95	mAP50
A RF-DETR + DINOv2-S	COCO全量/80类	30.467	0.483	0.674
B RF-DETR + DINOv2-S	COCO 5k/80类	30.467	0.483	0.673
C RF-DETR + DINOv2-S	COCO 5k/VOC20	30.215	0.544	0.748
D RF-DETR + SATR骨干	COCO 5k/VOC20	9.577	0.006	0.017
E RF-DETR + DINOv2-S	M3FD可见光	30.467	0.493	0.782
F RF-DETR + SATR骨干	M3FD可见光	9.829	0.315	0.561
原始完整SATR-SSM	M3FD既有协议	3.72	0.435	0.706

5.1 最佳轮次与运行记录

表6 最佳权重轮次与训练记录

组	训练轮数	最佳日志轮次	日志训练耗时h	训练图像
A	20	8	48.00	118287
B	20	1	4.72	5000
C	20	2	4.13	5000
D	20	20	9.63	5000
E	100	91	9.43	2100
F	100	98	21.22	2100

最佳日志轮次已换算为从1开始。耗时直接读取train.log的Training time，包含训练循环中的逐轮验证。完整COCO的图像位于fs盘，5k子集位于tmp盘，路径与I/O差异一并记录。

5.2 数值与模型对应

六组最终评估的权重SHA256均与在线附件中的实际最佳模型匹配；六组完整保存预测经COCOeval重新计算，12项COCO指标与最终验证JSON逐项一致；最佳日志轮次来自普通与EMA逐轮记录。每组的metrics.json、resolved_config.json、run_status.json随包保留，完整预测通过在线附件下载。

6 完整COCO与配对子集

6.1 A/B：在相同80类上比较

A的mAP50:95为0.483，B为0.483，未舍入原值相差+0.019个百分点；当次训练约48.00小时与4.72小时。官方COCO预训练后的低学习率微调，在当前任务与验证集上保留了接近的基线表现。该观察为后续采用固定5k图像作为对照载体提供依据。

6.2 B/C：统一到共同20类

表7 共同类别评价

比较空间	B：80类模型	C：20类模型	C-B
共同VOC20类AP	0.543	0.544	+0.061个百分点
各自全部类别AP	0.483（80类）	0.544（20类）	标签空间不同，分列展示

只减少类别数仍会保留图像前向的主要计算量；本项目降低训练压力的主要措施是把训练图片从118287张收缩为固定5000张。B/C共同类别结果接近，标签过滤本身没有带来同一标签空间中的明显精度变化。

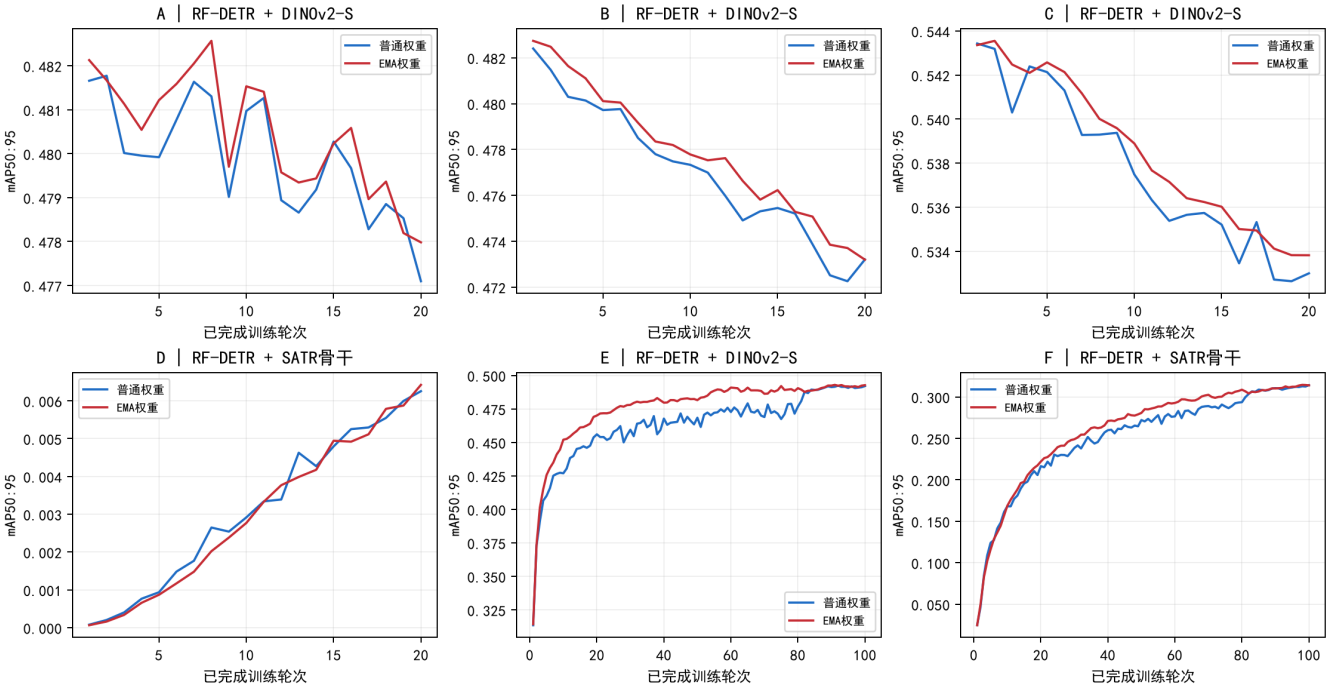


图3 六组逐轮验证AP曲线，由原始JSON日志生成。曲线对应各任务本身的评价空间，B/C的共同类比较单独列于上表。

7 SATR迁移：精度与参数规模

7.1 COCO20与M3FD的成对结果

表8 骨干迁移的精度与参数规模

指标	C → D（COCO20）	E → F（M3FD）
mAP50:95	0.544 → 0.006	0.493 → 0.315
mAP50	0.748 → 0.017	0.782 → 0.561
Δ mAP50:95	-0.537	-0.178
参数量M	30.215 → 9.577	30.467 → 9.829
参数减少	68.30%	67.74%
日志训练耗时h	4.13 → 9.63	9.43 → 21.22

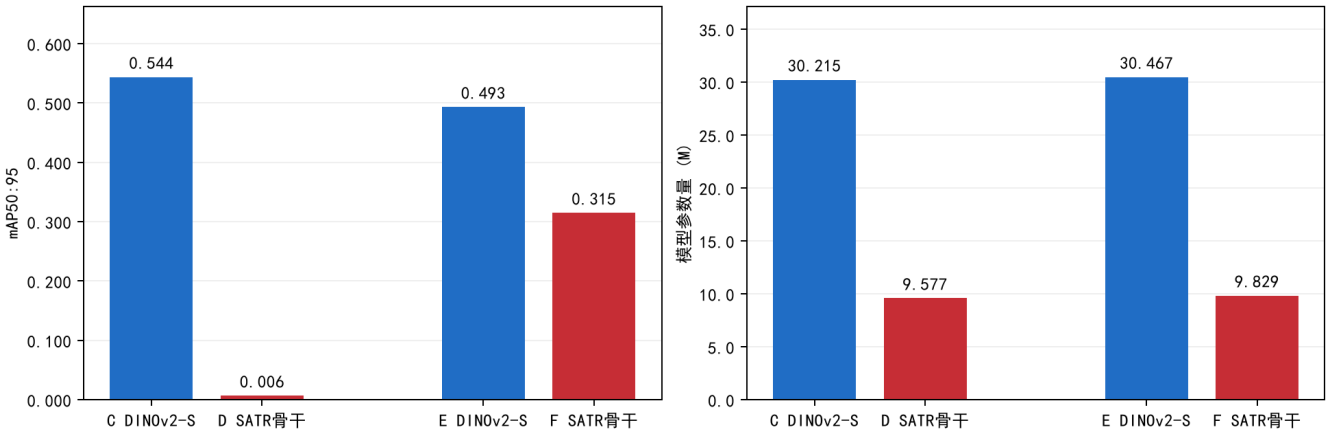


图4 DINOv2-S基线与SATR骨干迁移模型结果。AP为0至1的小数；ΔAP由未舍入原值相减后保留三位小数。训练耗时取原始日志Training time。

7.2 收敛记录

表9 训练损失与最佳轮次

组	首轮平均训练损失	末轮平均训练损失	最佳轮次
C	3.487	2.846	2
D	11.165	7.194	20
E	4.492	2.609	91
F	7.986	4.308	98

D在第20轮取得当前最佳，损失水平仍高于C；F经过100轮已形成检测能力，最佳EMA在第98轮，但精度仍低于E。后续优先围绕接口优化节奏与特征组合开展对照。

7.3 为什么A/B/C较早达到最佳

表10 首末轮验证表现、最佳轮次与训练起点

组	首轮EMA AP	末轮EMA AP	最佳EMA轮次	训练起点
A	0.482	0.478	8	COCO完整预训练
B	0.483	0.473	1	COCO完整预训练
C	0.543	0.534	2	COCO预训练；分类行映射
D	0.000	0.006	20	M3FD骨干；新接口
E	0.314	0.493	91	COCO预训练→M3FD
F	0.025	0.314	98	M3FD骨干；新接口

A/B/C的最佳EMA分别在第8、1、2轮。A/B从官方COCO完整检测权重开始，C还按类别语义抽取分类头行，骨干、投影器和解码器已经适配COCO。因此首轮验证AP已较高，后续训练主要是继续微调既有能力。

A/B/C的训练损失分别由3.770、3.754、3.487下降到3.616、3.357、2.846，验证AP总体回落。这种训练拟合继续改善而验证性能下降的组合，提示任务过适配或预训练表征漂移。A的最佳位于中前期，B/C更靠前；五千张子集的接近表现建立在COCO预训练基础上。

7.4 为什么D/E/F较晚达到最佳

D在M3FD来源的SATR骨干上接入新适配层，再跨域进入COCO20；原COCO解码器要接收新的特征分布。主LR为1e-5，预算20轮，其最佳在预算末轮，AP仍很低而曲线继续上升。F沿用M3FD来源骨干，仍需学习新的RF-DETR接口；主LR为1e-4，预算100轮，最佳EMA在第98轮。

E使用DINOv2-S与完整COCO初始化，同样需要适配M3FD的目标外观、类别和尺度分布，最佳EMA在第91轮。E/F在第80轮前的主LR为1e-4，第81轮开始衰减，后期稳定在1e-5。后期最佳出现在两种骨干配置中，结合其训练起点分析，目标域适配、接口学习与较长优化预算共同影响了曲线。

综合来看，A/B/C是在已对齐的检测器上继续微调，D/F还承担新接口学习，E承担目标域迁移。后续把适配层独立学习率、预热、分阶段解冻和特征统计对齐作为具体实验因素，分离初始化、结构和优化节奏的影响。

8 学习率与特征对齐审计

8.1 实际学习率与参数更新

表11 适配层和编码器更新记录

模块	D：COCO2O	F：M3FD
新适配层初始LR	1e-5	1e-4
SATR编码器初始LR	1.5e-5	1.5e-4
解码器初始LR	7e-6	7e-5
独立适配阶段 / warmup	无 / warmup_epochs=0	相同
编码器相对L2变化	约1.18%	约8.69%
P3/P4/P5融合权重	0.3378/0.3323/0.3299	0.3180/0.3326/0.3494

正式GPU记录中，635个可训练张量全部进入优化器；真实Mamba分支和相关模块有梯度。权重核对显示409个编码器可训练张量均发生变化，适配层GroupNorm与融合系数也偏离初始值。学习率分组由最佳权重参数和对应源码还原。

原DINO编码器叠加层衰减和组件衰减，COCO2O初始实际LR约3.23e-7至7.35e-6；SATR编码器统一使用1.5e-5。相同配置字段对应的实际编码器优化策略存在差异，新适配层则与普通主网络参数共用基础学习率。

8.2 形状接口与预训练投影器

表12 特征接口与投影器核对

检查或结构	记录
输入逆归一化	往返最大绝对误差约5.96e-8
SATR特征	[B,128,48,48] / [B,128,24,24] / [B,256,12,12]
输出与mask	统一[B,256,24,24]；mask同步缩放，原位置编码保留
原投影器	约1.445M参数；多层拼接、C2f、逐位置通道LayerNorm
新适配层	0.133M参数；1×1卷积、GroupNorm、插值与加权和

形状和基本数值检查已经通过。接入后通道组合、归一化统计维度、投影容量和预训练状态均改变；本次目标函数未加入显式特征蒸馏或统计匹配。下一步将这些接口变化作为可独立检验的设计因素。

9 可视化、演示与失败案例

GT、原骨干、SATR骨干迁移使用相同图片；预测显示阈值统一为0.3。样例按已打包图片的image_id升序选取，展示选择和框数保留在demo_manifest.json。

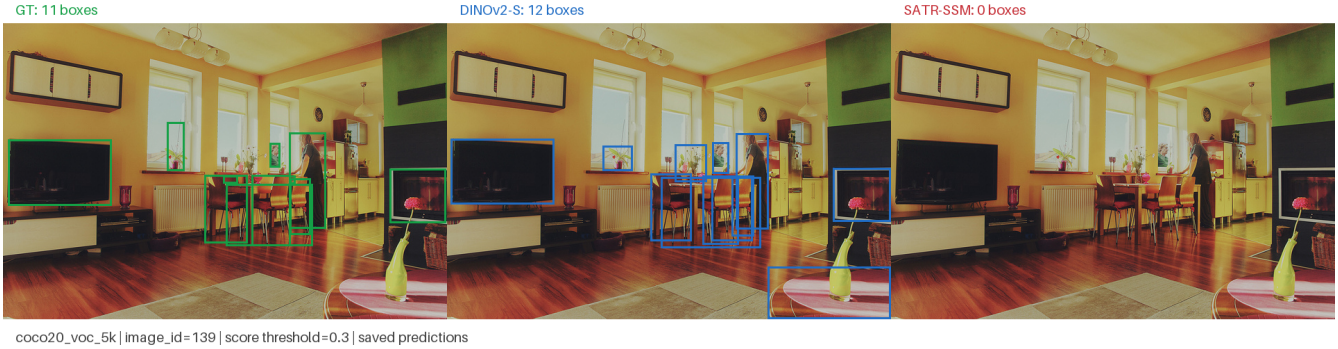


图5 COCO20样例，image_id=139。三列从左到右为GT、C组和D组。D组在当前阈值下显示响应较弱，与该任务整体AP较低一致。

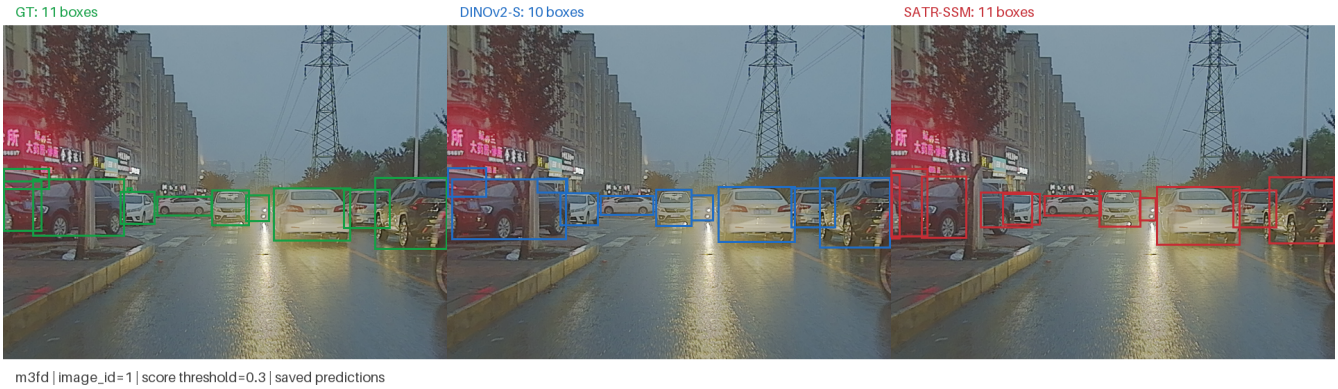


图6 M3FD样例，image_id=1。三列为GT、E组和F组。三列使用相同图像与阈值，车辆局部、重叠区域和小目标可与GT逐个对照。

9.1 失败表现与定位

COCO20的迁移表现突出为有效响应不足；M3FD中模型仍能定位部分车辆，但遮挡、重叠和较弱目标响应仍需改进。可视化使用保存预测而非重新生成结果，完整验证AP包括5000张COCO验证图和2100张M3FD验证图。

9.2 演示输出

results/demo提供两种数据各4张、共8张三列对照PNG；scripts/run_demo.sh可在CPU上重新绘制同一保存预测。课程要求的“演示视频或示例输出”采用示例输出形式。

10 问题来源与后续实验设计

表13 问题分析与后续检验

结构或日志观察	对应改进方向	检验方式
新适配层与预训练部分同步起步	适配层独立LR、warm-up与分阶段解冻	保持数据与轮数，比较接口更新策略
1.445M预训练投影器变为0.133M新模块	保留/蒸馏原投影器，提高映射容量	比较同一骨干下的投影器结构与初始化
拼接+LN变为插值+GN+标量求和	多尺度拼接、统计对齐与教师特征约束	记录各尺度特征及通道统计
COCO20在预算末轮仍取得最佳	重新分配适配与联合训练预算	先用短程对照观察稳定性与损失趋势

10.1 优先补齐G组

原计划还包括“SATR原检测体系 + COCO20/5k”，图像与标签空间与C/D完全相同。课程时间截止前来不及完成，列为下一组优先实验。G组用于分离原体系中的骨干能力与跨框架接口变化，再组织G与D的同任务比较。当前结果中不填写该组数值。

10.2 环境、任务与结论范围

基线使用Python3.11，SATR使用Python3.12以复用已验证的原生wheel。同一C/E权重跨环境推理的mAP50:95差异均小于0.001个百分点，回归检查通过；训练Python差异继续保留在实验描述中。

本轮只有seed=0；报告呈现当前固定任务上的数值，而跨运行波动需后续多种子评估。M3FD使用已有优势域和既有SATR权重；COCO官方初始化已包含原任务预训练。类别过滤、预训练来源、投影模块更换和验证集别名均在协议中明确记录。

本次分析将已核对的结构/优化事实与待执行设计放在不同列。学习率、投影器和特征语义的相对作用，由后续成对消融区分；本轮不追加训练。

11 复现入口、材料与完整性

11.1 提交结构

表14 提交目录与材料

根目录内容	对应证据
proposal.pdf / report.pdf / presentation.pptx	选题分工、报告与最终19页PPT
src/	RF-DETR基线训练评估及固定上游源码；SATR实现排除
data/	来源链接、60张样例及固定划分；完整标注外置
checkpoints/	模型下载链接、SHA256及结构元数据
logs/	原始文本、逐轮JSON与6个TensorBoard事件文件
results/	图表、样例预测、对照、审计及演示
scripts/ / requirements.txt / LICENSE.txt	统一入口、依赖及许可

11.2 执行顺序

公开训练与重新推理入口仅提供A/B/C/E四组RF-DETR基线，按docs/复现说明.md创建Python3.11环境。先下载模型、标注及原始图片，再由prepare_data.py恢复固定任务。D/F保留原始配置、日志、指标和保存预测，不提供SATR骨干、适配层、兼容补丁及导出/训练实现。

```
bash scripts/train.sh --group C --dataset /datasets/course/coco20_voc_5k --output /runs/C_reproduce

bash scripts/evaluate.sh --group E --dataset /datasets/course/m3fd --output /runs/E_valid

python scripts/render_demo.py --output runs/demo_replay
tensorboard --logdir logs/tensorboard
```

11.3 提交核验

六份最佳权重已匹配最终评估哈希，在线清单提供下载与SHA256；固定上游源码62个清单文件逐项核对。文本日志与TensorBoard事件保持原始数据，结果表由最终验证JSON读取。公开源码限于RF-DETR基线，SATR全部实现与源码下载已排除；SATR pipeline和RF-DETR参数截图保留。提交整理不启动新训练，不改写历史实验日志。

12 小组分工、心得与总结

学号20242054，黄刘昱泽，单人组队，课程实验工作总占比100%。第三方算法与现有SATR论文在引用处标明；下表统计本次课程实验任务的个人完成比例。

表15 单人分工占比

课程任务	负责人	占整体工作比例
选题、论文与任务分析	黄刘昱泽	10%
环境、依赖与兼容检查	黄刘昱泽	15%
数据划分与RF-DETR基线	黄刘昱泽	20%
SATR接口与两组迁移实验	黄刘昱泽	25%
结果、日志与失败分析	黄刘昱泽	15%
报告、PPT与复现材料整理	黄刘昱泽	15%
合计	单人	100%

心得与总结

本次实验将“模型能运行”推进到“结果能解释、材料能复核”。完整COCO运行后，固定同源子集帮助控制了对照成本；共同类别评价避免把不同标签空间的总体AP当作类别收缩收益。迁移时，特征尺寸、参数梯度与权重重载全部通过，检测精度仍显著下降，分析因此围绕预训练投影器、归一化和优化节奏组织后续实验。

最终完成六组真实训练和验证，建立COCO20与M3FD两条迁移对照；SATR骨干迁移使模型参数减少约68%，当前接口仍有精度损失。后续先补齐G组原体系对照，再检验投影器保留、独立适配学习率和多尺度特征约束。

参考文献与代码来源

[1] Robinson I., et al. RF-DETR: Neural Architecture Search for Real-Time Detection Transformers. ICLR 2026. openreview.net/forum?id=qHm5GePxTh。
[2] SATR-SSM项目（大创成果，既有完整检测器及其骨干）。github.com/TingFeng36/SATR-SSM。
[3] Oquab M., et al. DINOv2: Learning Robust Visual Features without Supervision. arXiv:2304.07193.
[4] Gu A., Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. arXiv:2312.00752.
[5] Lin T.-Y., et al. Microsoft COCO: Common Objects in Context. ECCV 2014.
[6] RF-DETR固定代码：github.com/roboflow/rf-detr/tree/1.3.0。
[7] Liu J., et al. Target-Aware Dual Adversarial Learning and a Multi-Scenario Multi-Modality Benchmark To Fuse Infrared and Visible for Object Detection. CVPR 2022. M3FD数据：github.com/JinyuanLiu-CV/TarDAL。